

GUÍA Y CONCEPTOS CLAVE DE MACHINE LEARNING

Explicación práctica de clasificación, regresión y regresión logística

Aprendiz: [Juan Sebastian Molina Betancourt]

1. Entendiendo la diferencia: ¿Clasificación o Regresión?

Para empezar a trabajar con Machine Learning supervisado, lo primero que debemos tener claro es qué tipo de respuesta estamos buscando:

- **Regresión:** La usamos cuando necesitamos predecir un número con decimales que puede variar libremente. Por ejemplo, calcular el precio exacto de una casa, la temperatura de un servidor o cuántos kilos de papa se van a vender la próxima semana.
- **Clasificación:** La usamos cuando la respuesta es una categoría fija. Aquí no hay términos medios: o es una cosa o es otra (como decir si un correo es spam o seguro, o si un cliente va a cancelar su contrato).

2. ¿Cómo funciona la Regresión Logística?

Aunque tenga la palabra "regresión" en su nombre, este algoritmo sirve para **clasificar**. Es genial porque es rápido, fácil de entender y no es una "caja negra" difícil de auditar.

- **El problema de la línea recta:** Si intentáramos usar una línea recta común para adivinar cosas que son 0 o 1, terminaríamos con datos absurdos, como decir que hay un 150% de probabilidad de que algo pase o un -20%. Eso no tiene lógica en la vida real.
- **La solución (la curva en S o Sigmoide):** Para arreglar esto, la regresión logística usa una función matemática con forma de "S" acostada. No importa qué tan exagerados sean los datos de entrada, esta curva siempre aplana el resultado para que la probabilidad se mantenga estrictamente entre 0 y 1 (es decir, entre 0% y 100%).
- **El umbral de decisión:** Por defecto, el sistema corta la decisión en el 50% (0.5). Si pasa de ahí, lo manda al grupo de los "sí" (1); si queda por debajo, lo manda al grupo de los "no" (0). En cosas delicadas como detectar fraudes o enfermedades, este límite se puede mover para ser más precavidos.

3. Soluciones a la Actividad 1: Identificando los casos

Caso	Descripción	Tipo de Modelo	Por qué se clasifica así
1	Kilos de papa	Regresión	Da un número exacto y continuo con decimales.
2	Correos maliciosos	Clasificación	Es una categoría fija: o es malicioso o es seguro.
3	Score crediticio	Regresión	Estima una puntuación numérica en una escala continua.
4	Cancelación de contrato	Clasificación	El cliente toma un camino binario: se va (1) o se queda (0).
5	Precio de una casa	Regresión	Calcula un valor monetario continuo exacto.
6	Triaje de urgencias	Clasificación	Categoriza al paciente en una de dos opciones de atención.

4. Respuestas a las Actividades 2, 3, 4 y 5

- **El error de la recta (Actividad 2):** Al trazar una línea recta tradicional, se obtienen valores imposibles para una probabilidad, como números negativos o mayores a 1. La herramienta matemática que acomoda todo entre 0 y 1 se llama **función sigmoide**.
- **Interpretación:** Si un coeficiente sale negativo (ej. -1.34 en un hábito de salud), significa que tener esa característica reduce la probabilidad de ocurrencia. El *p-value* (menor a 0.05) valida si esa relación es confiable frente al azar.
- **Matriz de Confusión y Errores (Actividad 3):** La exactitud (*accuracy*) se calcula sumando los aciertos y dividiéndolos entre el total de casos. En finanzas o salud, un **falso negativo** (dejar pasar un fraude o una enfermedad real) es mucho más peligroso que una falsa alarma.
- **Correlación y Multicolinealidad (Actividad 4):** La matriz mide la relación entre variables con el coeficiente de Pearson. Si dos variables independientes están demasiado conectadas entre sí, confunden al modelo y dañan sus resultados.
- **Sobreajuste (*Overfitting*):** Ocurre cuando el modelo "estudia tanto" los datos viejos que se los memoriza. Saca un 100% en las pruebas internas, pero cuando se enfrenta a clientes reales en la calle, falla porque no aprendió a pensar, solo a repetir.

5. Código Base para Práctica en Python

Estructura general recomendada para implementar el modelo de regresión logística:

```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import confusion_matrix, accuracy_score

# 1. Cargar y separar los datos (X = características, y = objetivo)
# X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

# 2. Escalar los datos para que tengan la misma magnitud
# scaler = StandardScaler()
# X_train_scaled = scaler.fit_transform(X_train)
# X_test_scaled = scaler.transform(X_test)

# 3. Entrenar el modelo de Regresión Logística
# modelo = LogisticRegression(random_state=42)
# modelo.fit(X_train_scaled, y_train)

# 4. Evaluar resultados con los datos de prueba
# y_pred = modelo.predict(X_test_scaled)
# print("Precisión del modelo:", accuracy_score(y_test, y_pred))
```

6. Conclusiones

La regresión logística es la puerta de entrada ideal al aprendizaje supervisado gracias a su simplicidad y claridad. Saber interpretar sus coeficientes y métricas permite ajustar los umbrales según el nivel de riesgo real de cada negocio.