

Taller: Algoritmo de Árboles de Decisión

Socialización de Algoritmos de Clasificación Supervisada | Grupo de Aprendizices

A. Conceptos Fundamentales

1. ¿Qué es el algoritmo?

Es un modelo de aprendizaje supervisado de estructura jerárquica que predice el valor de una variable objetivo mediante la aplicación secuencial de reglas de decisión simples inferidas de las características de los datos.

2. Tipo de aprendizaje y problemas que soluciona

Pertenece al **Aprendizaje Supervisado**. Permite resolver problemas de **clasificación** (categorizar en clases discretas, ej: Sí/No, Alto/Medio/Bajo) y también de regresión numérica.

3. Funcionamiento e Idea Matemática

Comienza en la raíz con todo el conjunto de datos y evalúa qué atributo separa mejor las clases mediante criterios estadísticos de impureza como la **Ganancia de Información (Entropía)** o el **Índice de Gini**, minimizando la incertidumbre en los subconjuntos hijos de forma recursiva.

B. Funcionamiento (Pipeline del Algoritmo)

El flujo operativo sigue las etapas estándar de Machine Learning adaptadas a su naturaleza estructurada:

Etapa Pipeline	Descripción Operativa en Árboles de Decisión
1. Datos	Recopilación de dataset estructurado con variables predictoras (features) y etiqueta objetivo.
2. Preprocesamiento	Limpieza de nulos y transformación de variables categóricas a numéricas (One-Hot Encoding). No requiere escalado.
3. Entrenamiento	Construcción jerárquica de nodos y ramas ajustando hiperparámetros como profundidad máxima.
4. Modelo & Predicción	Modelo persistido que evalúa nuevas observaciones recorriendo nodos lógicos hasta una hoja final.

C. Características del Algoritmo

Estructura y Datos

Compuesto por nodos raíz, nodos de decisión y nodos hoja. Maneja eficientemente variables tanto numéricas (continuas/discretas) como categóricas.

Hiperparámetros Clave

- **max_depth:** Limita la profundidad para evitar sobreajuste.
- **criterion:** 'gini' o 'entropy'.
- **min_samples_split:** Mínimo de muestras para dividir un nodo.

D. Ventajas y Limitaciones

Ventajas Principales

- **Alta Interpretabilidad:** Su estructura gráfica tipo diagrama de flujo es sumamente intuitiva de leer, explicar y visualizar para perfiles no técnicos.
- **Mínimo Preprocesamiento:** No requiere normalización, estandarización ni escalado de las variables de entrada para operar de forma correcta.
- **Manejo de Datos Mixtos:** Procesa nativamente conjuntos de datos que combinan atributos cuantitativos y cualitativos sin transformaciones complejas.

Limitaciones Principales

- **Inestabilidad Estructural:** Pequeñas variaciones o ruido en los datos de entrenamiento pueden alterar drásticamente la estructura completa del árbol.
- **Tendencia al Sobreajuste (Overfitting):** Si se permite un crecimiento libre sin restricciones, el modelo memoriza los datos en lugar de generalizar patrones.
- **Sesgo por Clases Desbalanceadas:** Tiende a generar estructuras sesgadas si una categoría domina numéricamente de forma abrumadora en el dataset.

E. Aplicaciones Reales

- **Riesgo Crediticio:** Evaluación automatizada por entidades financieras para aprobar o denegar préstamos basados en ingresos e historiales.
- **Diagnóstico Médico:** Clasificación asistida de pacientes con base en sintomatología y reportes clínicos previos.
- **Fuga de Clientes (Churn):** Identificación de perfiles con alta probabilidad de cancelar un servicio para planificar campañas de retención.

F. Implementación Práctica en Python (Scikit-Learn)

Script completo estructurado paso a paso desde la carga de datos hasta la predicción:

```
import pandas as pd
from sklearn.datasets import load_iris
from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeClassifier, plot_tree
from sklearn.metrics import accuracy_score, precision_score, recall_score, f1_score,
confusion_matrix
import matplotlib.pyplot as plt

# 1 y 2. Carga y exploración básica del dataset
data = load_iris()
X = pd.DataFrame(data.data, columns=data.feature_names)
y = data.target
print("Primeras filas:\n", X.head(3))

# 3 y 4. Preparación y división (80% entrenamiento, 20% prueba)
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

# 5 y 6. Creación y entrenamiento del modelo
clf = DecisionTreeClassifier(criterion='gini', max_depth=3, random_state=42)
clf.fit(X_train, y_train)

# 7. Predicción sobre el conjunto de prueba
y_pred = clf.predict(X_test)

# 8. Evaluación de métricas
print("\nExactitud (Accuracy):", accuracy_score(y_test, y_pred))
print("Matriz de Confusión:\n", confusion_matrix(y_test, y_pred))
```

Interpretación de Código

El script utiliza el dataset clásico *Iris*, separa las muestras de forma aleatoria garantizando reproducibilidad (`random\_state=42`), entrena el árbol limitando su profundidad a 3 niveles y genera las predicciones para su contraste posterior.

G. Evaluación del Modelo e Interpretación de Resultados

Para socializar adecuadamente los resultados obtenidos en la ejecución del script, se analizan las siguientes métricas clave de desempeño:

1. Exactitud (Accuracy)

Mide el porcentaje global de predicciones correctas frente al total de muestras evaluadas en el conjunto de prueba. Un valor cercano a 1.0 indica alta efectividad general del árbol.

2. Precisión (Precision)

Determina de todas las predicciones positivas realizadas por el modelo para una clase específica, qué proporción correspondía realmente a la categoría correcta (minimiza falsos positivos).

3. Exhaustividad (Recall)

Cuantifica la capacidad del modelo para identificar correctamente todas las instancias reales existentes de una clase en particular (minimiza falsos negativos).

4. Puntuación F1 (F1-score)

Representa la media armónica entre la Precisión y el Recall. Ofrece una visión equilibrada del rendimiento, siendo especialmente útil cuando existen desequilibrios moderados entre clases.

5. Matriz de Confusión

Permite visualizar de forma detallada y matricial los aciertos y las confusiones específicas del modelo, mostrando exactamente qué clases está logrando separar correctamente y cuáles confunde entre sí.